

Cronograma Detallado y Especificación Técnica: SARA

Asistente Institucional Inteligente - Facultad de Ingeniería

Duración: 5 Meses (22 Semanas / 11 Sprints)

Metodología de Trabajo

Este documento establece el plan de ejecución detallado para el proyecto SARA. Se trabajará bajo un marco ágil con Sprints de 2 semanas. El Supervisor (Arquitecto) liderará las ceremonias de Planning y aprobará las integraciones mediante Pull Requests.

Fase 0: Preparación y Capacitación (Mes 1)

Sprint 1 (Semanas 1-2): Setup

- - Dev 1: Capacitación React Three Fiber y Web Audio API. Entregable: Cubo 3D interactivo y captura de audio en consola.
- - Dev 2: Capacitación LangChain y setup de ChromaDB Dockerizado. Entregable: Ingesta básica de texto a vectores.
- - Supervisor: Setup de repositorios (Git), creación del docker-compose.yml base, recolección de PDFs. Definición del contrato API inicial.

Fase 1: El Cerebro RAG (Mes 1-2)

Sprint 2 (Semanas 3-4): Motor RAG Base

- - Dev 1: Maquetado UI principal del quiosco en React y setup de Zustand/Context.
- - Dev 2: Pipeline de ingesta (pdf-parser, chunking de 1000 tokens) y creación de endpoint POST /api/chat.
- - Supervisor: Auditoría de limpieza de texto en chunks. Revisión de Pull Requests.

Sprint 3 (Semanas 5-6): LLM Cloud y Guardrails

- - Dev 1: Consumo de endpoint, manejo de UI states (Loading, Error, Success).
- - Dev 2: Integración OpenAI/Gemini API, System Prompts estrictos y prevención de off-topics.
- - Supervisor: Sesión conjunta de QA (Pruebas de estrés y Guardrails).

Fase 2: Cuerpo 3D y Voz (Mes 3)

Sprint 4 (Semanas 7-8): STT, TTS y Avatar GLTF

- - Dev 1: Carga de modelo 3D (Ready Player Me) en Canvas. Lógica de Push-to-Talk.
- - Dev 2: Integración Whisper (Audio -> Texto) y TTS (Texto -> Audio + Visemas).
- - Supervisor: Revisión de arquitectura de latencia y streaming de audio.

Sprint 5 (Semanas 9-10): Lip-sync y Animación Continua

- - Dev 1: Manipulación de morphTargets basada en visemas para sincronización labial.
- - Dev 2: Optimización de tiempos de respuesta. Caché de respuestas frecuentes.
- - Supervisor: Integración crítica en conjunto (Dev 1 + Dev 2) para alinear timing de frontend y backend.

Fase 3: Hardware y On-Premise (Mes 4)

Sprint 6 (Semanas 11-12): Sensores y Kiosko

- - Dev 1: UI responsiva a pantallas táctiles (1080p/4K) y teclado en pantalla.
- - Dev 2: Script para sensor PIR/Webcam conectado por WebSocket para despertar UI.
- - Supervisor: Armado físico del hardware local e instalación de OS y drivers GPU.

Sprint 7 (Semanas 13-14): Migración a Llama 3

- - Dev 1: Ajustes menores y manejo de contingencias offline.
- - Dev 2: Setup de Ollama local, Llama 3 (8B), y re-vectorización con embeddings locales (HuggingFace).

- - Supervisor: Monitoreo térmico y de VRAM en servidor local bajo estrés concurrente.

Fase 4: Panel Admin y Lanzamiento (Mes 5)

Sprint 8 (Semanas 15-16): Backend Admin

- - Dev 1: Ruta /admin protegida para gestión documental (Subida/Listado).
- - Dev 2: Endpoints CRUD seguros para manejo dinámico de ChromaDB.
- - Supervisor: Auditoría de seguridad del panel administrativo.

Sprint 9 (Semanas 17-18): Pruebas Alpha (Sitio)

- - Trabajo conjunto: Instalación del quiosco en pasillo. Calibración de sensibilidad táctil y umbrales de micrófono bajo ruido ambiental real.
- - Supervisor: Recolección de métricas de uso y tasa de errores de STT.

Sprint 10 & 11 (Semanas 19-22): Pulido Final y Entrega

- - Dev 1 & Dev 2: Bug fixing intensivo, refactorización y resolución de deuda técnica.
- - Supervisor: Redacción de manuales (Técnico y Usuario), cierre de repositorios (v1.0) y entrega a la Facultad.

Fase 0: Preparación y Capacitación (Mes 1)

Objetivo: Nivelación técnica, configuración de repositorios y definición de contratos API.

Sprint 1 (Semanas 1 - 2): Setup y Capacitación

- **Dev 1 (Frontend):**
 - Curso/Práctica: React Three Fiber, carga de modelos .glTF (Ready Player Me), luces y cámaras virtuales.
 - Práctica: Captura de audio del navegador usando Web Audio API.
 - Entregable: Un cubo 3D girando en Vite y un botón que grabe 5 segundos de audio y lo imprima en consola.
- **Dev 2 (Backend):**
 - Curso/Práctica: Node.js con LangChain, conceptos de *Embeddings* y *Chunking*.
 - Práctica: Setup de ChromaDB en Docker.
 - Entregable: Un script en Node que lea un .txt, lo divida y lo guarde en ChromaDB local.
- **Supervisor (Tú):**
 - Creación de repositorios (GitHub/GitLab) con políticas de ramas (main, develop, feature/*).
 - Creación del docker-compose.yml base (Node + Vite + ChromaDB).
 - Recolección de PDFs reales de la facultad.
 - **Punto de Integración:** Definir en conjunto el JSON exacto (Contrato Swagger) que el Front enviará al Back para hacer una pregunta.

Fase 1: El Cerebro (Mes 1 y 2)

Objetivo: Flujo de texto a texto funcional usando RAG. El sistema debe poder leer PDFs y responder.

Sprint 2 (Semanas 3 - 4): Motor RAG y Estructura Base

- **Dev 1 (Frontend):**
 - Maquetado de la UI principal del quiosco (Pantalla de reposo, botón central, área de transcripción de texto).
 - Implementación de manejo de estado (Zustand o Context API).
- **Dev 2 (Backend):**
 - Desarrollo del pipeline de ingesta (pdf-parser). Ajuste del tamaño de *chunks* (ej. 1000 tokens) y *overlap* (200 tokens).
 - Creación del endpoint POST `/api/chat` que reciba una pregunta, busque en ChromaDB y arme el *Prompt*.
- **Supervisor (Tú):**
 - Revisión de PRs (Pull Requests).
 - Auditoría de los fragmentos guardados en ChromaDB para validar que el texto extraído del PDF sea limpio (sin basura de encabezados o pies de página).

Sprint 3 (Semanas 5 - 6): LLM en Nube y Guardrails

- **Dev 1 (Frontend):**
 - Consumo del endpoint `/api/chat`.
 - Manejo de estados de carga (Loading spinners) y manejo de errores (ej. "Error de conexión").
 - **Dev 2 (Backend):**
 - Integración de la API de OpenAI/Gemini en el endpoint.
 - Implementación del *System Prompt* estricto y lógica de "Guardrails" (si la respuesta de ChromaDB está vacía, forzar al LLM a decir "No sé").
 - **Supervisor (Tú):**
 - **Punto de Integración:** Sesión conjunta (Dev 1 y Dev 2) de pruebas de estrés. Tú intentarás engañar a SARA preguntándole cosas indebidas o fuera de contexto para probar los límites del modelo.
-

Fase 2: El Cuerpo y la Voz (Mes 3)

Objetivo: Convertir el chat de texto en una experiencia interactiva y visual con el avatar 3D.

Sprint 4 (Semanas 7 - 8): STT, TTS y Base 3D

- **Dev 1 (Frontend):**
 - Reemplazar la UI estática por el Canvas 3D. Cargar el modelo del Avatar.
 - Implementar el botón *Push-to-Talk* que grabe audio (Blob) y lo envíe al Back.
- **Dev 2 (Backend):**
 - Integración de Whisper (Audio a Texto).
 - Integración de TTS (Texto a Audio). Extraer la respuesta del LLM, convertirla en audio y retornar el buffer de audio + los metadatos de los *visemas* (tiempos de las vocales).
- **Supervisor (Tú):**
 - Validar la arquitectura de streaming. Si SARA genera una respuesta larga, el usuario no puede esperar 10 segundos en silencio. Revisar con Dev 2 cómo hacer un envío segmentado.

Sprint 5 (Semanas 9 - 10): Lip-sync y Animación

- **Dev 1 (Frontend):**
 - Desarrollo crítico: Lógica matemática que tome los visemas del Backend y manipule los morphTargets del rostro 3D en sincronía con la reproducción del audio.
- **Dev 2 (Backend):**
 - Optimización de la latencia de red. Implementación de caché de preguntas frecuentes.
- **Supervisor (Tú):**
 - **Punto de Integración:** Aquí es donde más suelen chocar. Dev 1 y Dev 2 deben trabajar en llamada/presencial para alinear el

timing del audio con la respuesta JSON. Tú auditarás la fluidez visual.

Fase 3: Hardware y Migración On-Premise (Mes 4)

Objetivo: Preparar el sistema para correr sin internet en el hardware físico de la facultad.

Sprint 6 (Semanas 11 - 12): Sensores y Despliegue Local

- **Dev 1 (Frontend):**
 - Ajuste de la UI para la resolución de la pantalla táctil (1080p o 4K).
 - Animaciones de reposo del Avatar (parpadeo, respiración).
- **Dev 2 (Backend):**
 - Script auxiliar en Python o Node para leer la señal del sensor de movimiento (o webcam) y emitir un evento WebSocket al Front para "despertar" al Avatar.
- **Supervisor (Tú):**
 - Armado del quiosco físico (Mini PC, Monitor, Cables).
 - Instalación de Ubuntu/Windows, Docker y drivers.

Sprint 7 (Semanas 13 - 14): Switch a Llama 3 (On-Premise)

- **Dev 1 (Frontend):**
 - Ajustes menores de UI, no debería haber cambios estructurales si la API se mantuvo igual.
- **Dev 2 (Backend):**
 - Instalación y configuración de Ollama en el contenedor Docker local.
 - Cambio de variables de entorno para apuntar a la API local.
 - Re-vectorización: Cambiar los *embeddings* de OpenAI a modelos de HuggingFace locales.
- **Supervisor (Tú):**

- Pruebas de estrés térmico de la GPU. Monitorear el uso de VRAM cuando el modelo Llama 3 (8B) esté respondiendo preguntas concurrentes.

Fase 4: Panel Admin, QA y Lanzamiento (Mes 5)

Objetivo: Entregar un sistema administrable por la facultad y a prueba de estudiantes.

Sprint 8 (Semanas 15 - 16): Panel de Administración

- **Dev 1 (Frontend):**
 - Creación de una ruta oculta /admin con autenticación básica.
 - UI para listar documentos cargados, botón para eliminar y drag-and-drop para subir nuevos PDFs.
- **Dev 2 (Backend):**
 - Endpoints CRUD seguros (POST /upload, DELETE /doc/:id).
 - Lógica para eliminar vectores específicos de ChromaDB cuando se borra un PDF.
- **Supervisor (Tú):**
 - Auditoría de seguridad. Validar que un estudiante curioso no pueda acceder al panel ni borrar documentos.

Sprint 9 (Semanas 17 - 18): Pruebas Alpha en Sitio

- **Equipo Completo:** Instalación del quiosco en el pasillo de la facultad.
- **Dev 1:** Calibrar sensibilidad de los toques en pantalla.
- **Dev 2:** Ajustar umbral de ruido del micrófono y silencios (para saber cuándo el estudiante terminó de hablar).
- **Supervisor (Tú):** Recolección de métricas. ¿Cuántos falsos positivos tuvo el sensor de movimiento? ¿Entendió el modelo el acento local en un ambiente ruidoso?

Sprint 10 y 11 (Semanas 19 - 22): Bug Fixing, Pulido y Entrega

- **Devs:** Resolución de tickets de errores levantados en la prueba Alpha. Refactorización de código y eliminación de "deuda técnica".
- **Supervisor (Tú):**
 - Aprobación final de los Pull Requests.
 - Redacción del manual técnico y manual de usuario para la secretaría de la facultad.
 - Corte de rama release-1.0 y entrega oficial.